



CURSO: Engenharia de Computação (EC)

Projeto

Rev.: 08/08/2025

Disciplina: OPCPF-Processamento Digital de Imagens

Professor: Fabio Alexandre SPANHOL, faspanhol@gmail.com

Turma: CP94

Período: 9

Turno: Integral





1

Crie uma **base de imagens**. Utilize o **GitHub** para hospedar o projeto.

- Escolha um dos temas: (a) **fruits** (ft-DB) ou (b) **kitchen utensils** (KiUt-DB).
- Nomeie os itens em inglês com *underscore*, substituindo espaços quando necessário. Exemplos: (a) orange, apple, banana, mango, pineapple, guava, clementine, fig, etc. e (b) glass, mug, fork, pizza_cuter, spoon, pasta_server, pan, etc.
- Defina 10 classes, isto é, 10 frutas ou 10 utensílios. Crie uma tabela de codificação das classes, enumerando as classes 0...n-1. Ordene alfabeticamente os nomes das classes para codificar. Ex.:

0	apple
1	banana
2	clementine
...	...
9	yellow_passion_fruit

- Para cada item capture duas imagens em ângulos de visão diferentes (V1 e V2), variando dois fundos distintos (B e W). Faça esse procedimento para no mínimo 10 itens diferentes (instâncias) de cada classe. Não há máximo. A imagem seguinte ilustra as imagens para uma instância de uma classe específica.



- Utilize seu *smartphone* ou câmera digital para capturar imagens dos itens escolhidos. Cuidado com dimensões muito grandes!
- Aplique o mesmo corte para que todas as imagens tenham as mesmas dimensões (W x H).
- Exporte as imagens para o formato PNG.
- Codifique os nomes dos arquivos das imagens utilizando a regra **<CLASSID>-<IMG_SEQUENCE>-V1|V2-B|W.png**

Exemplo:


```
0-01-V1-B.png
0-01-V1-W.png
0-01-V2-B.png
0-01-V2-W.png
...
```



0-10-V2-B.png
0-10-V2-W.png

- Organize uma estrutura de diretório com um diretório para cada classe identificado com o nome da respectiva classe. Compacte a base de imagens em um arquivo tar.gz. Deve ser possível fazer o *download* da base de imagens.
- Crie um arquivo de metadados.
- Crie um **Jupyter Notebook (NB)**, usando Google Colab, para exibir as imagens, organizadas pelas classes. Dica: `skimage.util.montage`
- Crie uma função para exibir os metadados.

2 **Data annotation.** Faça a anotação dos objetos nas imagens, isto é, a marcação do **bounding-box** e a respectiva classe. Sugestão: Uso da ferramenta Web **CVAT** disponível em <https://app.cvat.ai/>



- Crie um **Jupyter Notebook (NB)**, usando Google Colab, para exibir as imagens originais e os respectivos *bounding-boxes*.



3 **Data augmentation.** Crie um **augmented_dataset**: uma versão aumentada em 3 vezes da base de imagens original.

- Aplique funções de **data augmentation** para aumentar a variabilidade de imagens da base. Veja <https://www.kaggle.com/code/parulpandey/overview-of-popular-image-augmentation-packages/notebook>

- Aplique pelo menos as funções:

Logaritmo da imagem
Exponencial da imagem
Filtro da média usando convolução

- Crie um **Jupyter Notebook (NB)**, usando Google Colab, para exibir as imagens, organizadas pelas classes. Dica: `skimage.util.montage`. Apresente a formalização matemática.

4 **Data normalization.** Crie um **normalized_dataset** utilizando equalização de histogramas.

- Calcule e apresente

Protótipo médio de cada classe
Histograma médio de cada classe
Variância do histograma de cada classe

- Crie um **Jupyter Notebook (NB)**, usando Google Colab, para exibir os resultados. Apresente a formalização matemática.

5 **Segmentação do objeto de interesse.**

- Segmente o objeto do seu fundo, gerando uma imagem binária (máscara): 0 para o fundo e 1 para o objeto. Dois tipos de segmentação serão usados (a) manual, para geração do *ground truth* e (b) automática usando algum algoritmo. Escolha um. Exemplo:





Imagem original



Ground truth

- O *ground truth* deve ser gerado para pelo menos 50% das amostras de cada classe.
- Crie um **Jupyter Notebook (NB)**, usando Google Colab, para gerar *bounding-box* (*bounding rectangle*) nas imagens.



6

Classificação. Obrigatório extrair *features* de cada imagem para treinar um classificador (p. ex., SVM, K-NN, etc.).

- Para cada imagem com *bounding-box* extraia características, gerando um *feature vector*. O extrator a ser utilizado é livre.
- Treine um classificador. Separe a base de imagens em 80% para treinamento, 10% para validação e 10% para teste.
- Calcule e apresente as métricas de classificação: acurácia média e F1-score.
- Apresente a matriz de confusão.
- Em seguida use uma CNN como classificador. Arquitetura livre.
- Use as imagens originais do ***augmented_dataset sem bounding-box***. Utilize a mesma divisão treinamento-validação-teste 80-10-10. Atente para que sejam os mesmos subconjuntos utilizados anteriormente.
- Para o modelo CNN, calcule as mesmas métricas de classificação (acurácia média e F1-score). Apresente a matriz de confusão. Compare o classificador anterior com a CNN usando curvas ROC.
- Crie um **Jupyter Notebook (NB)**, usando Google Colab.



"Today everything exists to end in a photograph."

Susan Sontag (1933-2004). American writer, philosopher, and political activist.