

Projeto de Processamento Digital de Imagens

Haynner Joner Mattos*

SUMÁRIO

1	IDENTIFICAÇÃO DO PROJETO E REPOSITÓRIOS	1
2	DESCRIÇÃO DA BASE DE IMAGENS ORIGINAL (FT-DB)	1
3	DATA AUGMENTATION E NORMALIZAÇÃO	1
3.1	Formalização Matemática	2
3.2	Normalização e Estatísticas	2
4	RESULTADOS FINAIS DA CLASSIFICAÇÃO	3
4.1	Abordagem Clássica (Extração de Características + SVM)	3
4.2	Abordagem Deep Learning (CNN)	3
4.3	Análise Comparativa via Curva ROC	3

1 IDENTIFICAÇÃO DO PROJETO E REPOSITÓRIOS

- **Repositório Oficial no GitHub (Base de Imagens):**
<https://github.com/HayJM/Projeto.git>
- **Arquivo Compactado da Base Original (.tar.gz):**
<https://github.com/HayJM/Projeto/blob/main/Projeto.tar.gz>
- **Endereços dos Jupyter Notebooks (Google Colab):**
 - **Notebook 1 (Base e Anotação):** [ColeolinkdoColab1aqui]
 - **Notebook 2 (Data Augmentation e Normalização):** [ColeolinkdoColab2aqui]
 - **Notebook 3 (Segmentação e Classificação):** [ColeolinkdoColab3aqui]

2 DESCRIÇÃO DA BASE DE IMAGENS ORIGINAL (FT-DB)

A base de dados desenvolvida foca no tema *Fruits* (ft-DB). As imagens foram coletadas via dispositivos móveis sob condições controladas de iluminação. Foram definidas 10 classes, ordenadas alfabeticamente para a codificação automática de 0 a $n - 1$, conforme a Tabela 1.

Para cada instância/item de fruta, capturaram-se imagens sob dois ângulos de visão distintos ($V1$ e $V2$) variando entre dois fundos controlados: Branco (B) e Preto (W), seguindo rigidamente o padrão de nomenclatura [Código]-[Instância]-[Visão]-[Fundo].png. Todas as imagens foram padronizadas espacialmente através de cortes homogêneos de dimensões fixas e exportadas no formato PNG.

3 DATA AUGMENTATION E NORMALIZAÇÃO

*  Universidade Tecnológica Federal do Paraná, Toledo, Paraná, Brasil.  haynnermattos@alunos.utfpr.edu.br.

Tabela 1 – Tabela de codificação e estrutura das classes da base ft-DB.

Código	Nome da Classe (Inglês)	Descrição do Item	Instâncias Mínimas
00	00_Cherry_Tomatoes	Tomate Cereja	10
01	01_Fig	Figo	10
02	02_Gala_Apple	Maçã Gala	10
03	03_Pear	Pera	10
04	04_Persimmon	Caqui	10
05	05_Pitanga	Pitanga	10
06	06_Pomegranate	Romã	10
07	07_Sicilian_Lemon	Limão Siciliano	10
08	08_Strawberry	Morango	10
09	09_Tangerine	Tangerina	10

3.1 Formalização Matemática

Para expandir a variabilidade da base de dados original em exatamente 3 vezes, utilizou-se o desdobramento de cada imagem em 3 novas versões artificiais embasadas nos seguintes operadores:

1. **Transformação Logarítmica:** Expansão de contraste em zonas de baixa intensidade (subexpostas):

$$s = c \cdot \log(1 + r), \quad \text{onde } c = \frac{255}{\log(1 + \max(f))} \quad (1)$$

2. **Transformação Exponencial (Correção Gamma):** Ajuste não-linear de brilho atuando sobre pixels normalizados no intervalo $[0, 1]$ com parâmetro adotado $\gamma = 0.5$:

$$s = c \cdot r^\gamma \quad (2)$$

3. **Filtro da Média Espacial via Convolução:** Operação linear de suavização com máscara discreta normalizada (Kernel 5×5):

$$g(x, y) = \frac{1}{25} \sum_{i=-2}^2 \sum_{j=-2}^2 f(x + i, y + j) \quad (3)$$

3.2 Normalização e Estatísticas

A normalização deu-se pela equalização global de histogramas através do mapeamento da Função de Distribuição Acumulada (CDF):

$$s_k = \frac{L - 1}{MN} \sum_{j=0}^k n_j \quad (4)$$

Em sequência, gerou-se para cada classe o *Protótipo Médio* ($\mathbf{P}_c$), o *Histograma Médio* ($\bar{h}_c$) e a *Variância do Histograma* (σ_c^2) expressos por:

$$\mathbf{P}_c(x, y) = \frac{1}{N_c} \sum_{i=1}^{N_c} f_i(x, y); \quad \bar{h}_c(k) = \frac{1}{N_c} \sum_{i=1}^{N_c} h_i(k) \quad (5)$$

$$\sigma_c^2(k) = \frac{1}{N_c} \sum_{i=1}^{N_c} (h_i(k) - \bar{h}_c(k))^2 \quad (6)$$

4 RESULTADOS FINAIS DA CLASSIFICAÇÃO

4.1 Abordagem Clássica (Extração de Características + SVM)

A partir da segmentação automática executada via limiarização adaptativa de Otsu no canal de Saturação (S) do espaço HSV, extraiu-se o vetor contendo atributos de Cor (Matiz/Hue Médio: μ_H), Forma (Circularidade: $C = \frac{4\pi A}{P^2}$ e *Aspect Ratio*: $AR = \frac{W}{H}$) e Textura via descritores GLCM (Contraste e Homogeneidade).

Submetidos à divisão homogênea de dados (80% treino, 10% validação e 10% teste), o classificador clássico obteve uma **Acurácia Global de 82.50%**, demonstrando excelente isolamento para a classe 00_Cherry_Tomatoes (F1-Score: 1.00), porém exibindo degradação e confusões marginais em classes semelhantes como 02_Gala_Apple e 06_Pomegranate.

4.2 Abordagem Deep Learning (CNN)

Uma Rede Neural Convolucional de arquitetura livre (3 camadas convolucionais alternadas com max-pooling, camada de dropout a 0.5 e uma densa final Softmax de 10 neurônios) foi treinada sobre o *augmented_dataset* original (sem bounding-box). A CNN atingiu **83.00% de acurácia média de teste**, com picos de generalização de **90.31% na 12ª época**, eliminando os antigos gargalos da extração manual de formas geométricas.

4.3 Análise Comparativa via Curva ROC

A validação estatística final e definitiva do projeto foi consolidada por meio do cálculo da Área Sob a Curva ROC (*Macro-Average Area Under the Curve*), cujos resultados numéricos foram:

- **Métrica AUC da CNN:** 0.9844
- **Métrica AUC do Classificador Clássico:** 0.6373

Os valores obtidos provam que o espaço latente e os filtros convolucionais extraídos de forma autônoma pela arquitetura de Deep Learning garantem um limiar de separabilidade entre as 10 classes de frutas drasticamente superior ao modelo matemático tradicional.